以網站特徵與L2正則化邏輯斯迴歸辨識釣魚網站

第八組

研究背景與動機

資安防護需求

辨識偽裝網站，防範憑證與個資外洩，精準權衡漏報與誤報風險

杜絕資料洩漏 (Data Leakage)

處理解析5,206筆重複資料，採Group-based分組切分防範驗證偏差

高可解釋性 Logit 模型

採用L2邏輯斯迴歸，提供機率輸出與可量化的特徵權重解釋力

希望利用網站本身的特徵, 建立一個**二元分類模型**, 判斷網站是否為釣魚網站

- 降低釣魚網站的漏判風險
- 同時控制合法網站被誤判為釣魚網站的情況
- 建立具有**可解釋性與可重現性**的分類流程

研究問題

1. 網站的哪些特徵有助於辨識釣魚網站？
2. L2正則化邏輯斯迴歸能否有效區分釣魚與合法網站？
3. 資料中的大量重複特徵組合，是否可能造成資料洩漏，進而高估模型表現？

核心目的

二元分類模型：精準識別釣魚網站（Phishing）與合法網站（Legitimate）。

降低漏判風險：極小化假陰性（FN），避免使用者個資與憑證遭竊取。

權衡誤報率 (FPR)：避免過度攔截合法網站，維持良好的使用者體驗。

關鍵指標：以 Recall（召回率）與 FPR（誤報率）作為核心優化平衡點。

研究邊界

× **不涵蓋資訊轟炸：**資料集缺乏使用者行為與頻率，無法直接評估資訊過載。

× **不作時間泛化驗證：**缺乏原始 URL、網域 ID 與時間戳記，僅限靜態特徵評估。

× **歷史特徵侷限：**特徵規則基於歷史資料，不宜宣稱為現今網站之絕對安全規則。

範疇控制：專注於已知特徵空間中的機器學習模型嚴謹性與可重現性。

資料集概覽: UCI Phishing Websites

總資料筆數
11,055
無空值與缺失欄位

輸入特徵數
30
已進行編碼與離散化

釣魚網站 (Class 0)
4,898
佔總體 44.31%

合法網站 (Class 1)
6,157
佔總體 55.69%

資料類別	原始 ARFF 標籤	轉換後 CSV 標籤	資料筆數	百分比
釣魚網站 (Phishing)	-1	0 (定義為正類)	4,898	44.31%
合法網站 (Legitimate)	1	1	6,157	55.69%

30項特徵構面分類與 值域解析

網址列特徵 (Address Bar)

包含 12 項特徵：

- having_IP_Address (-1, 1)
- URL_Length (-1, 0, 1)
- Shortining_Service (-1, 1)
- Prefix_Suffix (-1, 1)
- SSLfinal_State (-1, 0, 1) ...等

異常與 HTML/JS 特徵

包含 11 項特徵：

- Request_URL (-1, 1)
- URL_of_Anchor (-1, 0, 1)
- SFH (-1, 0, 1)
- Iframe (-1, 1)
- on_mouseover (-1, 1) ...等

網域與歷史統計特徵

包含 7 項特徵：

- age_of_domain (-1, 1)
- DNSRecord (-1, 1)
- web_traffic (-1, 0, 1)
- Page_Rank (-1, 1)
- Statistical_report (-1, 1)

特徵編碼說明：多數欄位離散化為 {-1, 0, 1}（分別代表 Phishing, Suspicious, Legitimate）。Redirect 僅包含 {0, 1}。特徵數值非連續長度，屬離散化規則。

重複資料與資料洩漏處理

發現 5,206 筆重複資料

原始11,055筆資料中，僅包含**5,785組唯一特徵組合**。若直接隨機切分(Random Split)，將導致相同的網站特徵同時出現在訓練集與測試集，造成極端高估的效能(Data Leakage)。

64 組矛盾標籤處理

有64組特徵完全相同但標籤相反(同時存在釣魚與合法)。本研究選擇**保留衝突但不擅自更正**，改以相同特徵建立group_id進行分組切分。

專題防洩漏雙軌方案

1. 主分析方案 (Group-based Split)

按30個特徵組合建立Group ID，確保相同輸入特徵不跨訓練、驗證與測試集。

2. 敏感度分析(Unique Dataset)

去重後僅保留5,849筆唯一列(釣魚3,019/合法2,830)，比較兩者模型表現差異。

模型架構：L2正則化邏輯斯迴歸

數學模型定義

$$z = \mathbf{w}^T\mathbf{x} + b \quad \Rightarrow \quad p = \sigma(z) = \frac{1}{1+e^{-z}}$$

保留全部 30 項輸入特徵，包含 **30 個可學習權重 (\(w\))** 與 **1 個截距 (\(b\))**，共 31 個可學習參數。

目標函數與 L2 正則化

$$J(\mathrm{w}, b) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right] + \frac{\lambda}{2}\left\|\mathrm{w}\right\|_2^2$$

以二元交叉熵為損失函數，僅對權重向量 \(\mathbf{w}\) 施加 L2 懲罰（不懲罰截距 \(b\)），控制模型複雜度與過擬合。

模型設計特點

- **正類定義：**程式內令 \(y_{\text{phishing}} = 1 - \text{Result}\)，明確將釣魚網站設為正類。
- **決策門檻：**初始預設概率 Threshold = 0.5。
- **無隱藏層：**維持線性 Log-odds 假設，確保高可解釋性。

資料切分與交叉驗證流程 (Validation Pipeline)

STEP 01

三路切分 (80/10/10)

按 Group ID 分組切分為：80% 訓練集、10% 獨立驗證集、10% 最終測試集。

STEP 02

嚴格預處理 Standardize

StandardScaler 統計量**由每折訓練集估計**，不提前 transform 驗證/測試集。

STEP 03

5-Fold 交叉驗證

於 80% 訓練集內執行 StratifiedGroupKFold，尋找最佳超參數與縮放方案。

STEP 04

凍結評估 (Final Test)

於獨立驗證集確認門檻後，最後才對凍結的 10% 測試集進行單次最終評估。

基準模型實驗結果（Python 執行紀錄）

// 隨機森林 (Random Forest) 測試集混淆矩陣

TP (釣魚判釣魚) **942**	FN (釣魚判合法-漏報) **38**
FP (合法判釣魚-誤報) **19**	TN (合法判合法) **1212**

此為全資料隨機切分 20% 測試集之初步驗證結果

類別 (Class)	Precision	Recall	F1-score
Phishing (釣魚)	0.98	**0.96**	0.97
Legitimate (合法)	0.97	0.98	0.98
Overall Accuracy	**97.00% (2,211 筆測試資料)**		

隨機森林雖達成 97% 準確率，但因採普通隨機切分，可能含有資料洩漏成分。本專題擬以 Group Split 重新評估 L2 Logistic Regression 之真實泛化力。

文獻對比與批判性討論：Almujahid et al. (2024)

📖 對照論文研究 (PeerJ 2024)

- **文獻：**Almujahid, Haq, & Alshehri (2024), *PeerJ Computer Science*.
- **方法：**比較 LR、SVM、KNN、RF、XGBoost 及 CNN 深度模型。
- **結論：**作者稱 CNN 獲得最佳整體分類表現。

🔬 本專題之批判性反思

- 對照文獻在測試集中包含重採樣資料，有誇大指標疑慮。
- 測試集**不進行重採樣**，維持真實資料分配。
- **切分差異，**未處理重複特徵組合將導向過度樂觀的評估。

負責項目分工與 AI使用揭露

陳俐穎

資料集收集： UCI Phishing Websites 原始資料檢索與彙整

簡報設計： 統整內容製作專題簡報、排版

實驗與論文： 閱讀論文對照組與資料清整支援

何錦鵬

文獻整理： 分析 30 項網站特徵構面與定義分類目標

模型與評估計畫： 資料去重防洩漏 (Group Split)、L2 Logistic 模型搭建與 5-Fold 交叉驗證

報告準備： 統整進度與輔助報告發表流程

程式碼輔助編寫 (GitHub Copilot / Gemini)

輔助撰寫 GroupKFold 切分語法與數據視覺化圖表繪製程式碼。

文獻梳理與潤飾 (Claude 3.5 Sonnet)

用於摘要論文重點與協助簡報文案排版潤飾。

參考文獻與資料來源

1. **UCI Machine Learning Repository: Phishing Websites Dataset**
   Mohammad, A., Thabtah, F., & McCluskey, L. (2015). *Phishing Websites Dataset*. UCI Machine Learning Repository. https://doi.org/10.24432/C5B301 (11,055筆樣本與30項特徵構面)
2. **對照文獻批判研究 (PeerJ 2024)**
   Almujahid, H., Haq, N. U., & Alshehri, M. (2024). Comparative study of machine learning and deep learning models for phishing website detection. *PeerJ Computer Science*, 10, e-1892.
3. **實驗演算法與資料處理工具包**
   Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Thank You